

Large Language Models and Alignment ——Homework2

张硕 2401213265

2025 年 6 月 16 日

1 align-anything 部署

第一步是部署代码，这里首先 fork 网址：<https://github.com/PKU-Alignment/align-anything>，git clone 到本地，创建 conda 虚拟环境并激活，设置把环境变量写入 .bashrc 文件中，避免每次运行都要 source 一遍，最后安装要求的库依赖：pip3 install -e .[ascend]，即可完成代码基本部署

```
source /usr/local/Ascend/ascend-toolkit/set_env.sh
export LD_LIBRARY_PATH=/usr/local/Ascend/driver/lib64/driver:$LD_LIBRARY_PATH
```

第二步是下载模型，按照要求下载指定的模型，登录 hugging face 获取个人 hf_token，conda activate 虚拟环境之后，输入 huggingface-cli login，跟随指令输入 hf_token，在命令行执行 huggingface-cli download --resume-download PKU-Alignment/Beaver-0.5B-Instruct --local-dir LOCAL_DIR

第三步是下载数据集，这里的操作与下载模型十分类似，命令如下：huggingface-cli download --repo-type dataset --resume-download PKU-Alignment/PKU-SafeRLHF-single-dimension --local-dir LOCAL_DIR --local-dir-use-symlinks False，要替换保存路径。

2 奖励模型实现

2.1 偏好数据集键值转换

首先谈下我对问题的理解：

在大语言模型的对齐训练 RLHF 阶段，通常会使用“偏好数据集”来告诉模型：

“在这个问题（prompt）下，两个回答中，哪一个更好？”

不同的数据集用不同的字段来表达这种“哪一个回答更好”的结构，所以需要写一个“转换器”，统一它们的格式，以便系统能读懂。但 align-anything 训练框架只认统一格式，所以我需要做的是，为我使用的偏好数据集实现一个转换器（template），让框架能识别它的格式并转化为统一训练格式。具体代码如下：

Listing 1: HOMEWORK template 实现

```
from align_anything.configs.template import register_template, BaseFormatter
from typing import Any

@register_template('HOMEWORK')
class HOMEWORK(BaseFormatter):
    system_prompt: str = ''

    def format_preference_sample(
```

```

self, raw_sample: dict[str, Any]
) -> tuple[list[dict[str, Any]], list[dict[str, Any]], dict[str, Any]]:
    # 判断哪一个是最优的回答
    better_id = int(raw_sample['overall_response']) # 假设它是 "1" 或 "2"
    better_response = raw_sample[f'response_{better_id}']
    worse_response = raw_sample[f'response_{3-better_id}'] # 1+2=3

    prompt = raw_sample['question']

    # 构造 better conversation
    better_conversation = [
        {'role': 'user', 'content': prompt},
        {'role': 'assistant', 'content': better_response},
    ]

    # 构造 worse conversation
    worse_conversation = [
        {'role': 'user', 'content': prompt},
        {'role': 'assistant', 'content': worse_response},
    ]

    # 额外信息
    meta_info = {
        'better_text': better_response,
        'worse_text': worse_response,
    }

    return better_conversation, worse_conversation, meta_info

```

这段代码放在 `align_anything/configs/template.py` 中。

2.2 训练奖励模型

目前还没有服务器，该题暂时搁置

2.3 评测奖励模型

目前还没有服务器，该题暂时搁置

2.4 使用奖励模型可视化偏好数据集

目前还没有服务器，该题暂时搁置

2.5 回答问题

2.5.1 奖励建模有哪些应用？

奖励建模（Reward Modeling, RM）在大型语言模型的强化学习微调过程中很重要，是 RLHF（Reinforcement Learning from Human Feedback）流程的重要组成部分 [2]。RM 的核心作用，通俗来讲就是学习人类偏好评分函数，用于指导策略模型生成更加符合预期的文本。

具体应用包括：在 RLHF 中作为奖励函数，引导策略模型优化生成行为；在多候选生成任务中，如 Best-of-N 策略中，对多个答案进行打分并选择最优者 [3]；用于筛选高质量训练数据，降低人工标注负担；在训练分析中，RM 可用于诊断过拟合、长度偏差等问题；RM 的思想已推广至图像生成、游戏智能体控制等非文本任务中 [4]。

2.5.2 奖励建模训练可能存在哪些鲁棒性问题？

RM 在它的训练过程中，容易受到标注偏差、模型过拟合与分布不一致的影响。最明显的问题在于，对人类的反馈的评价标准往往难以存在严格意义上的好与坏，人类反馈具有主观性，不同标注者的标准可能不一致，导致标签噪声。除了上述问题之外，RM 训练过程可能对策略模型分布过拟合，缺乏泛化能力 [2]。此外，由于策略模型训练后分布变化，RM 也容易失效，引发策略模型“操纵”奖励模型的现象，即 reward hacking[4]，这会导致生成结果偏离真正的人类期望。

2.5.3 如何缓解奖励建模的长度偏差？

长度偏差是奖励建模中非常非常常见的问题，通俗一点的理解就是，对较长文本给予更高评分。这可能源于训练数据中的偏好趋势，也可能是模型训练过程中的归一化不足。缓解方法包括：对 reward 按长度进行归一化；使用 pairwise loss 替代回归损失，关注相对偏好而非绝对得分 [3]；在数据收集阶段平衡不同长度样本的分布 [5]。这些方法能够有效抑制 RM 在长度上的系统性偏差。

2.5.4 有哪些拟合多元人类偏好的奖励建模方法？

为建模不同用户群体的偏好差异，有研究提出以下方法：其一，引入混合建模或聚类机制，对多种偏好风格进行建模；其二，设计条件奖励模型（conditional RM），根据用户信息或偏好维度输出个性化评分；其三，通过多任务学习同时学习多个偏好维度（如有用性、礼貌性等）[5]，并在策略优化时加权组合多个 reward 信号。这些方法增强了模型对真实世界多样人类偏好的适应能力。

参考文献：

参考文献

- [1] Long Ouyang et al. *Training language models to follow instructions with human feedback*. NeurIPS, 2022.
- [2] Daniel Ziegler et al. *Fine-Tuning Language Models from Human Preferences*. arXiv preprint arXiv:1909.08593, 2019.
- [3] Yuntao Bai et al. *Training a Helpful and Harmless Assistant with RLHF*. Anthropic, 2022.
- [4] Anthropic. *Constitutional AI and multi-dimensional preference modeling*. 2023. <https://www.anthropic.com/index/claude-and-rlhf>

3 DPO 微调

3.1 运行 DPO 微调

目前还没有服务器，该题暂时搁置

3.2 评测 DPO 微调模型

目前还没有服务器，该题暂时搁置

3.3 回答问题

3.3.1 从强化学习的角度，DPO 是 on-policy 还是 off-policy 的，是 online 的还是 offline 的，为什么？

我认为，DPO (Direct Preference Optimization) 可以认为是一种 off-policy、offline 的强化学习方法。其“off-policy”属性在于它使用**固定的、历史采集的数据集**（通常为人类偏好对比数据），而不依赖于当前策略与环境交互生成新数据；“offline”属性则体现在模型训练过程中并不需要实时与环境交互，而是直接在已有的数据集上进行优化。

相比于传统 RLHF 中使用 PPO 等方法的 on-policy 训练，DPO 避免了昂贵的样本采集开销，且可以利用大规模现成的人类偏好对比数据进行高效训练 [1]。

3.3.2 DPO 主要针对传统 RLHF 的哪个方面进行了优化，关键见解是什么？

DPO 主要针对 ** 奖励建模 (Reward Modeling, RM) 及其后的强化学习阶段 ** 的问题进行优化。关键见解在于：** 避免显式训练 RM 和 PPO 策略微调的两个阶段 **，转而直接用人类偏好对比信号优化策略，从而减少噪声传播和训练不稳定性。DPO 采用一种最大化偏好对比概率的方式，直接从 pairwise 比较数据中优化策略，无需显式奖励模型 [1]。

这样不仅减少了 RM 中由于主观偏好、标签噪声和 reward hacking 导致的问题，也提高了样本效率与训练稳定性。

3.3.3 DPO 和传统 RLHF 相比有哪些局限性，具体体现在哪些方面？

DPO 可以认为是简化版的 RLHF 流程，但是简化之后存在以下几个局限：第一个就是依赖静态偏好对比数据，训练过程无法通过环境交互更新数据分布，可能导致泛化能力不足。第二个我认为是假设偏好一致性：DPO 优化目标基于成对样本的顺序一致性，难以处理偏好标签矛盾或多样性问题。第三个是无法直接进行 Reward 诊断与解释，由于没有明确的 RM 模块，DPO 在生成错误时难以追溯 reward 误导源。

此外，一些研究指出，DPO 优化可能受限于训练数据长度偏差和上下文分布差异等问题 [1]。

3.3.4 现有的研究 (KTO, SimPO, ORPO 等) 主要从哪些方面对 DPO 进行优化？

现有的这些改进版本的 DPO 的研究集中在以下几个方面：第一个是 KTO (KL-weighted Training Objective)，引入 KL 散度正则项来约束策略更新幅度，增强稳定性与保守性。第二个是 SimPO (Similarity-Guided Preference Optimization)，在 pairwise 优化中引入相似性约束，使策略对相似输入给出一致偏好。第三个是 ORPO (Orthogonal DPO)，通过正交投影对梯度进行去偏，减少无关特征干扰，提升策略泛化能力。

我认为这三项改进在本质上都在尝试从不同角度缓解 DPO 中的“信息不完整”与“训练不稳”两个核心问题，使其更可靠地学习偏好结构 [1]。

参考文献：

参考文献

- [1] Rafailov, R., Liu, A., Yang, K., et al. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*. arXiv preprint arXiv:2305.18290, 2023.
- [2] Long Ouyang et al. *Training language models to follow instructions with human feedback*. NeurIPS, 2022.
- [3] Daniel Ziegler et al. *Fine-Tuning Language Models from Human Preferences*. arXiv:1909.08593, 2019.
- [4] Yuntao Bai et al. *Training a Helpful and Harmless Assistant with RLHF*. Anthropic, 2022.
- [5] Anthropic. *Constitutional AI and multi-dimensional preference modeling*. 2023. <https://www.anthropic.com/index/claude-and-rlhf>

4 Bonus: 制作一个 text-to-text DPO 的 ipynb 文件

这道题我的理解是写一个 Jupyter Notebook, 实现 text-to-text 的 DPO 微调流程, 使用任意模型和数据, 确保能运行、损失函数正确, 最终形成一个.ipynb 文件提交。参考链接里的 https://github.com/PKU-Alignment/align-anything/blob/main/cookbooks/zh/text_image_to_text_sft.ipynb 内容是 image-to-text 的, 仅用来给我做参考格式结构和写作方式的。

具体实现流程见路径 Large-Language-Models-and-Alignment/hw2-code/Bonus, 具体实现过程见其中 ipynb 中的 markdown 讲解